



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS DE CRATEÚS
CURSO DE GRADUAÇÃO EM SISTEMAS DE INFORMAÇÃO

MARLON MELO MOURA

**AVALIAÇÃO DE DESEMPENHO DE ABORDAGEM QUÂNTICO-INSPIRADA PARA
REDUÇÃO DA DIMENSIONALIDADE EM DOMÍNIOS BIOINFORMÁTICOS**

CRATEÚS

2026

MARLON MELO MOURA

AVALIAÇÃO DE DESEMPENHO DE ABORDAGEM QUÂNTICO-INSPIRADA PARA
REDUÇÃO DA DIMENSIONALIDADE EM DOMÍNIOS BIOINFORMÁTICOS

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Sistemas de Informação
do Campus de Crateús da Universidade Federal
do Ceará, como requisito parcial à obtenção do
grau de bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Bruno Riccelli
Santos Silva

CRATEÚS

2026

MARLON MELO MOURA

AVALIAÇÃO DE DESEMPENHO DE ABORDAGEM QUÂNTICO-INSPIRADA PARA
REDUÇÃO DA DIMENSIONALIDADE EM DOMÍNIOS BIOINFORMÁTICOS

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Sistemas de Informação
do Campus de Crateús da Universidade Federal
do Ceará, como requisito parcial à obtenção do
grau de bacharel em Sistemas de Informação.

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Bruno Riccelli Santos Silva (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Rafael Simões do Carmo
Universidade Estadual Paulista (UNESP)

Prof. Dr. José Wellington Franco da Silva
Universidade Federal do Ceará (UFC)

AGRADECIMENTOS

Ao Prof. Dr. Bruno Riccelli Santos Silva por me orientar nessa jornada, ser um grande amigo, mentor e ter pacientemente me guiado durante todo o desenvolvimento deste trabalho. Agradeço por compartilhar seu conhecimento, experiência e entusiasmo pela pesquisa, tornando este processo de aprendizado mais enriquecedor e inspirador.

Aos meus pais, Francisco e Maria, por todo o amor, apoio e incentivo que me deram ao longo da minha vida. Sem eles, eu não teria chegado até aqui.

Aos amigos que fizeram parte dessa jornada, meu muito obrigado. Todas as caronas, as horas estudadas, as conversas, os momentos, as brigas e as risadas compartilhadas foram fundamentais para que eu chegasse até aqui. Agradeço por cada momento vivido, cada conselho dado e cada palavra de incentivo. Vocês estarão para sempre comigo.

“Quando percebes que nada te falta, o mundo inteiro te pertence.”

(Lao-Tsé)

RESUMO

A seleção de características desempenha um papel fundamental em problemas de aprendizado de máquina envolvendo conjuntos de dados de alta dimensionalidade, nos quais a presença de atributos redundantes, irrelevantes ou ruidosos pode comprometer o desempenho preditivo dos modelos e aumentar seu custo computacional. Nesse contexto, este trabalho propõe uma abordagem quântico-inspirada para seleção de características baseada em uma formulação de Otimização Quadrática Binária Irrestrita (QUBO), inspirada no critério Minimum Redundancy Maximum Relevance (mRMR). A relevância dos atributos será quantificada por meio da Informação Mútua, enquanto a redundância será estimada utilizando a correlação de Spearman. A otimização da formulação QUBO será realizada por meio da meta-heurística Simulated Annealing, executada em infraestrutura computacional clássica. A abordagem proposta será comparada aos métodos tradicionais ANOVA F-score, Recursive Feature Elimination with Cross-Validation (RFECV) e Lasso em três conjuntos de dados biomédicos de diferentes níveis de dimensionalidade: Ovarian Cancer Proteomic Dataset, Colon Cancer e Prostate Tumor. O desempenho dos subconjuntos selecionados será avaliado por meio dos classificadores Random Forest, K-Nearest Neighbors, Support Vector Machine, XGBoost, CatBoost e Optimum-Path Forest, utilizando validação cruzada estratificada do tipo k-fold, otimização de hiperparâmetros por Grid Search e teste estatístico de Wilcoxon. Espera-se que a abordagem proposta seja capaz de identificar subconjuntos de características mais compactos e menos redundantes, preservando a capacidade preditiva dos classificadores quando comparada a métodos tradicionais de seleção de características.

Palavras-chave: Seleção de características. QUBO. Simulated Annealing. Aprendizado de máquina. Alta dimensionalidade. Bioinformática.

ABSTRACT

Feature selection plays a fundamental role in machine learning problems involving high-dimensional datasets, where redundant, irrelevant, or noisy features may degrade predictive performance and increase computational cost. In this context, this work proposes a quantum-inspired feature selection approach based on a Quadratic Unconstrained Binary Optimization (QUBO) formulation inspired by the Minimum Redundancy Maximum Relevance (mRMR) criterion. Feature relevance will be quantified using Mutual Information, whereas redundancy will be estimated through Spearman correlation. The resulting QUBO formulation will be optimized using the Simulated Annealing metaheuristic executed on classical computing infrastructure. The proposed approach will be compared with traditional feature selection methods, namely ANOVA F-score, Recursive Feature Elimination with Cross-Validation (RFECV), and Lasso, using three biomedical datasets with different dimensionality levels: Ovarian Cancer Proteomic Dataset, Colon Cancer, and Prostate Tumor. The selected feature subsets will be evaluated using Random Forest, K-Nearest Neighbors, Support Vector Machine, XGBoost, CatBoost, and Optimum-Path Forest classifiers, combined with stratified k-fold cross-validation, Grid Search hyperparameter optimization, and the Wilcoxon signed-rank test. The proposed approach is expected to produce more compact and informative feature subsets while maintaining or improving predictive performance compared with traditional feature selection techniques.

Keywords: Feature selection. QUBO. Simulated Annealing. Machine learning. High-dimensional data. Bioinformatics.

LISTA DE FIGURAS

Figura 1 – Ilustração da Maldição da Dimensionalidade.	15
Figura 2 – Taxonomia clássica dos métodos de Seleção de Características.	16
Figura 3 – Ilustração Gráfica do Processo de <i>Quantum Annealing</i>	19
Figura 4 – Funcionamento do algoritmo <i>Simulated Annealing</i>	20
Figura 5 – Representação estrutural da matriz QUBO para seleção de características. .	23
Figura 6 – Random Forest Simplificado.	26
Figura 7 – Ilustração do Funcionamento do Algoritmo <i>KNN</i>	27
Figura 8 – <i>SVM</i> Simplificado.	28
Figura 9 – XGBoost Simplificado.	29
Figura 10 – CatBoost Simplificado.	30
Figura 11 – Algoritmo OPF.	31
Figura 12 – Validação Cruzada <i>k-fold</i>	32
Figura 13 – Visão geral da metodologia adotada.	41

LISTA DE TABELAS

Tabela 1 – Comparação entre os trabalhos relacionados e a abordagem proposta	40
Tabela 2 – Características dimensionais dos conjuntos de dados utilizados.	43
Tabela 3 – Cronograma de atividades do período de 2026.2	49

SUMÁRIO

1	INTRODUÇÃO	11
1.1	Objetivo Geral	12
1.2	Objetivos Específicos	12
1.3	Organização do Trabalho	13
2	FUNDAMENTAÇÃO TEÓRICA	14
2.1	Aprendizado de Máquina	14
2.1.1	<i>Maldição da Dimensionalidade</i>	15
2.1.2	<i>Métodos Clássicos de Redução de Dimensionalidade</i>	16
2.2	O Paradigma da Computação Quântica	17
2.2.1	<i>Quantum Annealing (QA)</i>	18
2.2.2	<i>Simulated Annealing (SA)</i>	19
2.3	CrITÉrio <i>mRMR: Minimum Redundancy Maximum Relevance</i>	21
2.4	Modelagem Matemática: Quadratic Unconstrained Binary Optimization (QUBO)	21
2.5	Mecanismos de Otimização Combinatória	24
2.6	Algoritmos de Classificação Para Avaliação de Desempenho	25
2.6.1	<i>Random Forest</i>	26
2.6.2	<i>K-Nearest Neighbors (KNN)</i>	27
2.6.3	<i>Support Vector Machine (SVM)</i>	28
2.6.4	<i>eXtreme Gradient Boosting (XGBoost)</i>	29
2.6.5	<i>Categorical Boosting (CatBoost)</i>	30
2.6.6	<i>Optimum-Path Forest (OPF)</i>	30
2.7	Validação Cruzada	32
2.8	Normalização Z-Score	32
2.9	<i>Grid Search</i>	33
2.10	Teste Estatístico de Wilcoxon	33
2.11	Métricas de Avaliação	34
2.11.1	<i>Acurácia</i>	34
2.11.2	<i>Precisão</i>	35
2.11.3	<i>Recall</i>	35

2.11.4	<i>F1-Score</i>	35
2.11.5	<i>Área Sob a Curva ROC (AUC-ROC)</i>	35
3	TRABALHOS RELACIONADOS	36
4	METODOLOGIA	41
4.1	Visão Geral	41
4.2	Conjuntos de Dados	42
4.2.1	<i>Ovarian Cancer Proteomic Dataset</i>	43
4.2.2	<i>Colon Cancer</i>	43
4.2.3	<i>Prostate Tumor</i>	43
4.3	Validação Cruzada K-Fold	44
4.4	Processamento em cada <i>fold</i>	44
4.4.1	<i>Normalização dos Dados</i>	44
4.4.2	<i>Geração de Subconjuntos de Características</i>	45
4.4.2.1	<i>ANOVA F-score (Filtro)</i>	45
4.4.2.2	<i>Recursive Feature Elimination with Cross-Validation (Wrapper)</i>	45
4.4.2.3	<i>Lasso (Embedded)</i>	45
4.4.2.4	<i>QUBO + Simulated Annealing</i>	46
4.4.3	Treinamento	46
4.4.4	Avaliação	47
4.4.5	Teste Estatístico	47
5	CRONOGRAMA	49
	REFERÊNCIAS	50

1 INTRODUÇÃO

A disseminação do uso de sistemas computacionais em todas as frentes do cotidiano humano eleva continuamente a capacidade de armazenamento e aquisição de dados. Em domínios como bioinformática, sistemas bancários e de monitoramento por sensores IoT, é comum lidar com bases contendo milhares de atributos para um número relativamente restrito de amostras. Embora essa volumetria eleve o potencial analítico desses dados, ela também impõe restrições ligadas a dimensionalidade dos dados e à complexidade computacional de modelos preditivos. Conforme discutido por Bishop (2006), nem toda característica disponível contribui para generalização do modelo. A presença de atributos redundantes, irrelevantes ou ruidosos eleva o custo computacional, obscurece a interpretabilidade e induz os algoritmos ao sobreajuste (*overfitting*) (LI *et al.*, 2017; MARTÍNEZ-GARCÍA *et al.*, 2025; YE *et al.*, 2026). Em cenários de alta dimensionalidade, o aumento do número de atributos também amplia o espaço de busca e reduz a densidade das amostras, tornando mais difícil para os algoritmos de aprendizado diferenciar corretamente as classes (BISHOP, 2006; SHAIKH *et al.*, 2025).

A seleção de características surge como resposta nesse cenário, buscando subconjunto de atributos que sejam ao mesmo tempo informativos para a classificação e pouco redundantes entre si. Porém encontrar um subconjunto ótimo é um problema de otimização combinatória NP-Difícil, visto que o espaço de busca cresce exponencialmente com o número de atributos. Por isso, heurísticas gulosas tendem a convergir prematuramente para mínimos locais, sem necessariamente captar as interações mais relevantes entre variáveis (MARTÍNEZ-GARCÍA *et al.*, 2025).

Uma alternativa que tem sido explorada consiste em modelar a seleção de características como um problema de Otimização Quadrática Binária, ou QUBO (NAU *et al.*, 2025). Nessa modelagem, cada atributo é representado por uma variável binária, enquanto a função objetivo incorpora simultaneamente a relevância individual das características e a redundância entre pares de atributos. Diferentemente de abordagens que avaliam os atributos de forma independente ou realizam buscas essencialmente gulosas, essa formulação permite otimizar esses critérios de maneira conjunta, ampliando a exploração do espaço combinatório na busca por subconjuntos mais compactos e informativos (YE *et al.*, 2026; SHAIKH *et al.*, 2025). A formulação QUBO pode ser resolvida tanto por *Quantum Annealing* (KADOWAKI; NISHIMORI, 1998), quanto por *Simulated Annealing* (KIRKPATRICK *et al.*, 1983). Na prática, porém, o uso de hardware quântico real ainda enfrenta limitações de conectividade e ruído típicas da era NISQ (*Noisy*

Intermediate-Scale Quantum) (BARRETO *et al.*, 2024) e disponibilidade restrita desses equipamentos. Isso torna o *Simulated Annealing* uma escolha viável para reproduzir o princípio de minimização de energia em infraestrutura computacional convencional (GALVÃO *et al.*, 2024).

Diante disso, este trabalho analisa a aplicação de uma formulação QUBO inspirada no critério mRMR (*Minimum Redundancy Maximum Relevance*), onde a matriz será modelada baseada em critérios de relevância e redundância, com a otimização conduzida pelo *Simulated Annealing*. A hipótese investigada é que essa estratégia seja capaz de produzir subconjuntos de características mais compactos, preservando o desempenho preditivo quando comparada a métodos tradicionais de seleção de características. O desempenho dessa abordagem será comparado a métodos clássicos de seleção de características em três conjuntos de dados de diferentes níveis de dimensionalidade, utilizando cinco algoritmos de classificação.

1.1 Objetivo Geral

Avaliar e comparar o desempenho e a eficácia de técnicas clássicas de seleção de características em relação a uma abordagem quântico-inspirada (QUBO + *Simulated Annealing*) para a classificação de problemas relacionados a bioinformática.

1.2 Objetivos Específicos

Para alcançar o objetivo geral, no contexto deste trabalho, foram estabelecidos os seguintes objetivos específicos:

- desenvolver uma formulação QUBO fundamentada no critério mRMR, utilizando a Informação Mútua para estimar a relevância dos atributos e a correlação de Spearman para modelar a redundância entre pares de características;
- implementar e comparar a abordagem proposta com métodos clássicos de seleção de características das categorias;
- avaliar o desempenho preditivo dos subconjuntos de características selecionados por meio de cinco algoritmos de classificação;
- avaliar métricas de Acurácia, Precisão, Recall, F1-Score e AUC-ROC;
- verificar, por meio do teste estatístico não paramétrico de Wilcoxon, a existência de diferenças estatisticamente significativas entre os métodos de seleção avaliados.

1.3 Organização do Trabalho

Este trabalho está organizado em quatro capítulos, além desta introdução. O Capítulo 2 apresenta a fundamentação teórica necessária à compreensão dos conceitos de aprendizado de máquina, seleção de características, computação quântica e quântico-inspirada, formulação QUBO e métricas de avaliação. O Capítulo 3 discute os trabalhos relacionados, contextualizando a presente pesquisa em relação ao estado da arte. O Capítulo 4 descreve a metodologia adotada, detalhando os conjuntos de dados, o processo de validação cruzada e as etapas de seleção de características, treinamento e avaliação. Por fim, o Capítulo 5 apresenta o cronograma planejado para o desenvolvimento das atividades.

2 FUNDAMENTAÇÃO TEÓRICA

No presente capítulo, são apresentados os elementos teóricos que fundamentam o desenvolvimento deste trabalho. Inicialmente, são abordados conceitos de aprendizagem de máquina, com ênfase na seleção de características e na maldição da dimensionalidade. Em seguida, são discutidos os paradigmas de computação quântica e quântico-inspirada, com foco em algoritmos de otimização baseados em *annealing*. Por fim, são detalhados o critério mRMR (*Minimum Redundancy Maximum Relevance*) e a modelagem matemática QUBO (*Quadratic Unconstrained Binary Optimization*), que servem como base para a formulação proposta neste trabalho. Os tópicos deste capítulo foram escolhidos para fornecer uma base teórica sólida que apoie a compreensão do tema deste trabalho.

2.1 Aprendizado de Máquina

O campo do Aprendizado de Máquina (*Machine Learning*) dedica-se ao desenvolvimento de algoritmos capazes de extrair, de forma automatizada, regularidades em conjuntos de dados (BISHOP, 2006). Essa abordagem baseia-se em modelos matemáticos adaptativos, cujos parâmetros são ajustados a partir de um volume de dados de um conjunto de treinamento. O objetivo central desse processo é alcançar a generalização (BISHOP, 2006).

As arquiteturas de aprendizado são classicamente categorizadas pela natureza do conjunto de treinamento. Quando o algoritmo recebe dados de entrada emparelhados aos seus respectivos valores ou gabaritos esperados (rótulos), a tarefa é definida como aprendizado supervisionado, que engloba os problemas de classificação (quando o alvo são categorias discretas) e de regressão (quando o alvo é uma ou mais variáveis contínuas). Inversamente, o aprendizado não supervisionado lida com a extração de estruturas intrínsecas a partir de dados não rotulados, com objetivos que incluem o agrupamento de similaridade (*clustering*), a estimativa de densidade ou a projeção de dados para fins de visualização (BISHOP, 2006).

Independentemente do paradigma adotado, o desempenho preditivo dos algoritmos é fortemente impactado pela forma como os dados brutos são apresentados à rede. Por essa razão, as variáveis de entrada quase sempre necessitam passar por uma etapa de pré-processamento e extração de características. O objetivo dessa fase é transformar o vasto espaço de entrada original em uma representação mais depurada, reduzindo variabilidades indesejadas e viabilizando o sucesso da tarefa de reconhecimento de padrões pelo algoritmo subsequente (BISHOP, 2006).


2.1.1 Maldição da Dimensionalidade

O desempenho e a capacidade de generalização dos modelos de Aprendizado de Máquina dependem fundamentalmente da qualidade e da representatividade dos dados de entrada (LI *et al.*, 2017). Em um cenário ideal, os dados forneceriam apenas as informações estritamente necessárias para a discriminação das classes, sem sobreposições (LI *et al.*, 2017). Na prática, contudo, o avanço das tecnologias de coleta gerou bases de dados de alta dimensionalidade (LI *et al.*, 2017). Nesses domínios, a quantidade de atributos excede a capacidade de processamento dos algoritmos tradicionais, inviabilizando a busca exaustiva por soluções ótimas (YE *et al.*, 2026). Consequentemente, o excesso de variáveis irrelevantes e ruídos estatísticos prejudica a precisão dos classificadores, o que induz os modelos ao *overfitting* e eleva drasticamente o custo computacional (LI *et al.*, 2017; YE *et al.*, 2026; GALVÃO *et al.*, 2024).

Para extrair sinal útil desse volume de dados, a literatura estabelece a Seleção de Características (Feature Selection) como uma etapa crucial no pré-processamento. Esta técnica visa identificar um subconjunto ótimo de características que seja informativo e relevante para a tarefa de classificação, reduzindo a dimensionalidade do espaço de entrada e, consequentemente, o risco de *overfitting* (YE *et al.*, 2026).

A identificação de um subconjunto ótimo que maximize a relevância informacional e minimize a redundância constitui um problema de otimização combinatorial classificado como NP-difícil (LI *et al.*, 2017). Dado um conjunto de p variáveis, o espaço amostral de subconjuntos possíveis totaliza 2^p , inviabilizando qualquer estratégia de busca exaustiva.

Figura 1 – Ilustração da Maldição da Dimensionalidade.




Fonte: Elaborado pelo autor.

2.1.2 Métodos Clássicos de Redução de Dimensionalidade

A literatura clássica de Aprendizado de Máquina categoriza os algoritmos de Seleção de Características em três vertentes principais, dependendo da estratégia de seleção e de como a busca interage com o algoritmo preditivo (LI *et al.*, 2017). Essas abordagens são classificadas como métodos de Filtro (*Filter*), *Wrapper* e *Embedded*.

Figura 2 – Taxonomia clássica dos métodos de Seleção de Características.



Fonte: Elaborado pelo autor.

1. Métodos de Filtro (*Filter*)

Os métodos de filtro operam de forma totalmente independente de qualquer algoritmo de aprendizado de máquina subsequente. Eles utilizam as características intrínsecas dos próprios dados para avaliar a relevância de cada atributo, o que os torna computacionalmente eficientes. Um método de filtro típico atua em duas etapas principais: primeiramente, a importância dos atributos é ranqueada com base em critérios estatísticos, da teoria da informação ou métricas de similaridade (como Variância, Teste Qui-quadrado, Informação Mútua ou Correlação); em seguida, as características com pontuações abaixo de um limiar predefinido são descartadas (filtradas) (LI *et al.*, 2017).

2. Métodos *Wrapper*

Diferentemente dos filtros, os métodos *Wrapper* utilizam o desempenho preditivo de um algoritmo de aprendizado de máquina predefinido como função de avaliação (atuando como

uma *black box*) para julgar a qualidade do subconjunto de características. O processo funciona de maneira iterativa: o algoritmo gera um subconjunto de atributos, treina o modelo preditivo com esses dados, avalia o desempenho (como a acurácia ou *F1-score*) e usa esse *feedback* para guiar a busca pelo próximo subconjunto (LI *et al.*, 2017).

3. Métodos Embarcados (*Embedded*)

Os métodos embarcados representam um balanço estratégico entre as abordagens de filtro e *wrapper*. Nesses métodos, a seleção de características é incorporada diretamente no processo de treinamento do modelo preditivo. Ou seja, o algoritmo simultaneamente ajusta os parâmetros de aprendizado do modelo e seleciona os atributos mais relevantes para a tarefa (LI *et al.*, 2017).

Adicionalmente, heurísticas clássicas de seleção de características, são propensas a convergir prematuramente para mínimos locais, falhando em capturar as interdependências não lineares e complexas entre as características. Para superar essas limitações, o uso de algoritmos de otimização inspirados em processos físicos, como o *Simulated Annealing* e o *Quantum Annealing*, tem se mostrado promissores para a exploração eficiente de espaços de busca combinatoriamente complexos, permitindo a identificação de subconjuntos de características que maximizam a relevância informacional e minimizam a redundância, mesmo em cenários de alta dimensionalidade (NAU *et al.*, 2025; MARTÍNEZ-GARCÍA *et al.*, 2025).

2.2 O Paradigma da Computação Quântica

A transição para abordagens quânticas altera a natureza do processamento de padrões ao substituir a lógica binária sequencial (bits 0 ou 1) pela manipulação de estados via qubits (BARRETO *et al.*, 2024). Essa mudança de paradigma permite codificar o espaço de busca de forma não linear, mitigando os gargalos computacionais observados em arquiteturas clássicas.

O paradigma quântico deriva de dois fenômenos físicos: a superposição e o emaranhamento (HASAN; MAHDY, 2024; BARRETO *et al.*, 2024). A superposição permite que um *qubit* represente simultaneamente uma combinação linear dos estados de base, conferindo ao sistema a capacidade de avaliar múltiplos estados de informação ao mesmo tempo (HASAN; MAHDY, 2024). O emaranhamento estabelece uma correlação que permite determinar o estado de um *qubit* a partir de outro, independentemente da distância, o que expande a capacidade de

processamento conjunto do sistema (BARRETO *et al.*, 2024; HASAN; MAHDY, 2024).

Essa arquitetura concede aos algoritmos quânticos a capacidade de explorar espaços de busca complexos com eficiência superior à dos métodos clássicos. (BARRETO *et al.*, 2024). No contexto do Aprendizado de Máquina e da otimização combinatória, essa característica natural de paralelismo quântico oferece uma vantagem computacional teórica relevante, especialmente para problemas classificados como NP-Difíceis, tais como a seleção exaustiva de subconjuntos ótimos de características em grandes volumes de dados (NAU *et al.*, 2025). Ao processar múltiplas combinações de forma simultânea e mapear estruturas de dados complexas, a computação quântica surge como alternativa para contornar gargalos onde algoritmos tradicionais saturam. (HASAN; MAHDY, 2024; BARRETO *et al.*, 2024).

2.2.1 *Quantum Annealing (QA)*


O *Quantum Annealing* (QA) é um processo de otimização meta-heurístico focado em encontrar o estado fundamental de funções objetivo complexas. O método QA é uma implementação inspirada na computação quântica adiabática, proposta originalmente a partir da evolução de um modelo de Ising em um campo transversal (KADOWAKI; NISHIMORI, 1998). Nesse processo, o sistema é inicializado no estado fundamental de um Hamiltoniano simples e conhecido e, de forma contínua, evolui por meio da diminuição da amplitude do campo transversal até alcançar o Hamiltoniano final que codifica o problema de otimização de interesse (KADOWAKI; NISHIMORI, 1998).

A principal vantagem do *Quantum Annealing* (QA) é o uso de flutuações e tunelamento quântico para atravessar barreiras energéticas, permitindo que o sistema escape de mínimos locais que costumam aprisionar as heurísticas térmicas tradicionais (KADOWAKI; NISHIMORI, 1998). Contudo, para a execução desse processo em um hardware físico, o problema deve ser obrigatoriamente mapeado em uma formulação matemática baseada em energia, como o modelo de Ising ou uma estrutura QUBO (*Quadratic Unconstrained Binary Optimization*) (NAU *et al.*, 2025).

Contudo, o emprego de processadores físicos de *Quantum Annealing* enfrenta restrições da era NISQ (*Noisy Intermediate-Scale Quantum*) (BARRETO *et al.*, 2024). Os dispositivos atuais frequentemente exigem técnicas complexas de incorporação (*embedding*) e métodos de subsamostragem ou esparsificação (*thresholding*) que descartam conexões para conseguir acomodar matrizes QUBO densas no chip (NAU *et al.*, 2025). Essas restrições topológicas podem

comprometer a fidelidade da otimização em problemas de alta dimensionalidade do mundo real (NAU *et al.*, 2025).

Figura 3 – Ilustração Gráfica do Processo de *Quantum Annealing*.



Fonte: Chamola *et al.* (2021)

Conforme ilustrado na Figura 3, o processo de *Quantum Annealing* pode ser interpretado como uma evolução gradual da paisagem de energia do sistema. Inicialmente, o Hamiltoniano do sistema é definido de modo a favorecer a exploração do espaço de busca, representado pela curva pontilhada preta. À medida que o processo evolui, a influência desse Hamiltoniano inicial é reduzida e a função objetivo do problema passa a dominar a dinâmica do sistema, representada pela curva tracejada. Ao final da evolução adiabática, o sistema é descrito pelo Hamiltoniano final (linha contínua preta), cuja configuração de menor energia corresponde à solução ótima do problema.

2.2.2 *Simulated Annealing* (SA)


Para contornar as limitações físicas de conectividade do hardware quântico atual, mantendo a formulação baseada em energia, o *Simulated Annealing* (SA) apresenta-se como a solução quântico-inspirada viável. O método utiliza os princípios da mecânica estatística e políticas de resfriamento termodinâmico para conduzir a exploração do espaço de busca (KIRKPATRICK *et al.*, 1983).

Ao contrário do QA, o *Simulated Annealing* (SA) baseia-se em flutuações térmicas simuladas, frequentemente orientadas pelo algoritmo de Metropolis (KIRKPATRICK *et al.*,

1983). Ao iniciar a busca sob uma temperatura algorítmica elevada, o sistema aceita transições temporárias para estados de maior energia, viabilizando a fuga de mínimos locais em superfícies complexas (KIRKPATRICK *et al.*, 1983). À medida que a temperatura decai seguindo um cronograma de resfriamento, a aceitação de soluções piores é progressivamente restringida, induzindo o algoritmo a convergir para o estado de energia mínima (KIRKPATRICK *et al.*, 1983).

A aplicação do *Simulated Annealing* a modelos QUBO para a seleção de características apresenta-se como uma alternativa viável para a otimização de atributos (MARTÍNEZ-GARCÍA *et al.*, 2025). Essa abordagem associa a modelagem matemática baseada em métricas de relevância e redundância à estabilidade de sistemas computacionais clássicos. Consequentemente, torna-se possível processar matrizes de alta dimensão sem os descartes topológicos exigidos pelos hardwares quânticos físicos atuais, preservando a reprodutibilidade e a precisão dos subconjuntos obtidos (NAU *et al.*, 2025).

Figura 4 – Funcionamento do algoritmo *Simulated Annealing*.



Fonte: Ledesma *et al.* (2008)

Conforme ilustrado na Figura 4, o *Simulated Annealing* realiza a busca por soluções por meio de um processo gradual de resfriamento. Nas etapas iniciais, quando a temperatura é elevada, o algoritmo possui maior probabilidade de aceitar soluções de maior energia, permitindo que a busca ultrapasse mínimos locais e explore diferentes regiões do espaço de soluções. À medida que a temperatura diminui, essa probabilidade é reduzida, tornando a busca progressivamente mais conservadora. Ao final do processo, o algoritmo converge para uma configuração de baixa energia, correspondente a uma solução próxima do mínimo global.

2.3 Critério *mRMR*: *Minimum Redundancy Maximum Relevance*

O critério *Minimum Redundancy Maximum Relevance*, proposto por Peng *et al.* (2005), é uma das abordagens mais difundidas para seleção de características em problemas de alta dimensionalidade. O método busca selecionar subconjuntos de atributos que apresentem elevada capacidade discriminativa em relação à variável alvo, ao mesmo tempo em que minimizam a redundância informacional existente entre as características selecionadas.

A motivação do *mRMR* decorre da observação de que atributos altamente relevantes para a tarefa de classificação podem fornecer informações muito semelhantes entre si. Nesses casos, a inclusão simultânea dessas variáveis aumenta a dimensionalidade do problema sem necessariamente acrescentar informação útil ao modelo. Dessa forma, o método procura equilibrar dois objetivos: maximizar a relevância e minimizar a redundância. Esse objetivo é expresso pela diferença entre as medidas de relevância (D) e redundância (R):

$$\Phi = D - R \quad (2.1)$$

em que D representa a relevância média das características selecionadas em relação à classe, enquanto R corresponde à redundância média entre essas características. Assim, quanto maior o valor de Φ , maior tende a ser a qualidade do subconjunto, pois ele reúne atributos informativos e com baixa sobreposição de informação.

Esse princípio pode ser incorporado à formulação QUBO. Nesse contexto, os termos da diagonal principal da matriz Q representam a relevância individual de cada atributo, incentivando sua seleção, enquanto os elementos fora da diagonal modelam a redundância entre pares de características, penalizando a seleção simultânea de atributos altamente correlacionados. Dessa forma, a minimização da função de energia da QUBO reproduz o princípio estabelecido pelo critério *mRMR*, favorecendo subconjuntos que maximizam a informação útil e minimizam a redundância.

2.4 Modelagem Matemática: Quadratic Unconstrained Binary Optimization (QUBO)

A modelagem via *Quadratic Unconstrained Binary Optimization* (QUBO) converte o problema combinatório de seleção de características em uma função de custo minimizável por algoritmos baseados em *annealing* (NAU *et al.*, 2025). O mapeamento define as variáveis de decisão como um vetor binário $x \in \{0, 1\}^P$, no qual $x_i = 1$ indica a inclusão do atributo i no

subconjunto selecionado e $x_i = 0$ a sua exclusão (NAU *et al.*, 2025). O objetivo consiste em minimizar a função escalar de energia associada a essa configuração.

A função de custo é governada por uma matriz quadrada Q de dimensão $p \times p$, expressa matricialmente por $E(x) = x^T Q x$, cuja expansão algébrica corresponde a:

$$E(x) = \sum_{i=1}^p Q_{ii}x_i + \sum_{i=1}^{p-1} \sum_{j=i+1}^p Q_{ij}x_i x_j \quad (2.2)$$

A estruturação da matriz Q determina a viabilidade da seleção de atributos, pois quantifica o poder preditivo individual das variáveis e a redundância informacional existente entre elas (LI *et al.*, 2017).

Os elementos da diagonal principal (Q_{ii}) representam o custo individual de seleção de cada atributo. A relevância de uma característica X_i frente à classe alvo Y é avaliada por meio da Informação Mútua (I) (NAU *et al.*, 2025), que mensura a informação compartilhada entre as variáveis conforme a equação:

$$I(X_i; Y) = \sum_{y \in Y} \sum_{x_i \in X_i} p(x_i, y) \log \left(\frac{p(x_i, y)}{p(x_i)p(y)} \right) \quad (2.3)$$

onde $p(x_i, y)$ é a função de distribuição de probabilidade conjunta de X_i e Y , enquanto $p(x_i)$ e $p(y)$ denotam as distribuições marginais correspondentes.

A métrica quantifica a redução da entropia da classe alvo Y proporcionada pelo conhecimento de X_i . Para priorizar os atributos mais informativos, os termos diagonais recebem o valor negativo da métrica, escalonado por um hiperparâmetro α (LI *et al.*, 2017):

$$Q_{ii} = -\alpha \cdot I(X_i; Y) \quad (2.4)$$

em que $I(X_i; Y)$ representa a Informação Mútua entre o atributo X_i e a variável alvo Y , enquanto α é um hiperparâmetro responsável por controlar a influência do termo de relevância na função objetivo. Caso as variáveis sejam independentes, tem-se $p(x_i, y) = p(x_i)p(y)$, o que anula o logaritmo e resulta em $I(X_i; Y) = 0$, indicando a ausência de valor preditivo.

Devido ao princípio de minimização global da função de custo, a atribuição do sinal negativo reduz a energia total do sistema quando variáveis com alta dependência informacional com a classe alvo são ativadas ($x_i = 1$) (NAU *et al.*, 2025).

Figura 5 – Representação estrutural da matriz QUBO para seleção de características.

	x_1	x_2	x_p
x_1	Q_{11} Relevância (x_1) Bônus (-)	Q_{12} Redundância (x_1, x_2) Penalidade (+)	Q_{1p} Redundância (x_1, x_p) Penalidade (+)
x_2	Q_{21} $Q_{21} = Q_{12}$	Q_{22} Relevância (x_2) Bônus (-)	... Penalidade (+)
x_p	Q_{p1} $Q_{p1} = Q_{1p}$	... $Q_{ij} = Q_{ji}$	Q_{pp} Relevância (x_p) Bônus (-)

Fonte: Elaborado pelo autor.

Os elementos fora da diagonal principal (Q_{ij} , com $i \neq j$) descrevem as interações quadráticas entre os atributos, visando mitigar a redundância informacional associada ao *over-fitting* dos classificadores (LI *et al.*, 2017). Essa dependência linear pode ser avaliada pelo Coeficiente de Correlação de Spearman (r_{ij}) entre as variáveis contínuas, determinado pela razão entre a covariância das características e o produto de seus respectivos desvios padrões (GALVÃO *et al.*, 2024):

$$r_{ij} = \frac{\text{cov}(X_i, X_j)}{\sigma_{X_i} \sigma_{X_j}} = \frac{\sum_{k=1}^n (x_{ik} - \bar{X}_i)(x_{jk} - \bar{X}_j)}{\sqrt{\sum_{k=1}^n (x_{ik} - \bar{X}_i)^2} \sqrt{\sum_{k=1}^n (x_{jk} - \bar{X}_j)^2}} \quad (2.5)$$

em que X_i e X_j representam as duas características analisadas, $\bar{X}_i$ e $\bar{X}_j$ correspondem às médias de cada atributo, σ_{X_i} e σ_{X_j} representam seus respectivos desvios padrão, $\text{cov}(X_i, X_j)$ denota a covariância entre as variáveis, x_{ik} e x_{jk} são os valores observados na k -ésima amostra e n representa o número total de amostras.

O intervalo de variação de r_{ij} compreende $[-1, 1]$, no qual valores extremos (1 ou -1) indicam dependência linear perfeita, positiva ou negativa. Nesses cenários, uma variável torna-se linearmente previsível a partir de outra, estabelecendo colinearidade na base de dados, enquanto valores próximos a 0 denotam a ausência de associação linear entre os atributos.

Embora amplamente utilizado, o coeficiente de Pearson é adequado principalmente para identificar associações lineares. Em situações nas quais a relação entre os atributos não é necessariamente linear, pode-se empregar o Coeficiente de Correlação de Spearman (ρ_{ij}), uma medida não paramétrica baseada nos postos das observações. A correlação de Spearman avalia a intensidade e a direção de relações monotônicas, sendo menos sensível à presença de valores extremos e à violação da hipótese de normalidade dos dados.

$$\rho_{ij} = 1 - \frac{6 \sum_{k=1}^n d_k^2}{n(n^2 - 1)} \quad (2.6)$$

em que d_k representa a diferença entre os postos atribuídos à k -ésima observação das variáveis analisadas e n corresponde ao número total de observações. Assim como o coeficiente de Pearson, o coeficiente de Spearman assume valores no intervalo $[-1, 1]$, em que valores próximos dos extremos indicam forte associação monotônica positiva ou negativa, enquanto valores próximos de zero sugerem ausência de associação monotônica entre os atributos (WINTER *et al.*, 2016).

Na formulação QUBO, considera-se a magnitude dessa dependência, independentemente de sua direção. Por esse motivo, os termos fora da diagonal recebem o valor absoluto do coeficiente ponderado por um hiperparâmetro β (GALVÃO *et al.*, 2024):

$$Q_{ij} = \beta \cdot |r_{ij}| \quad (2.7)$$

Essa estrutura estabelece que a seleção simultânea de duas características correlacionadas ($x_i = 1$ e $x_j = 1$) eleve a energia total do sistema. Desse modo, o processo de minimização prioriza subconjuntos com menor colinearidade, preservando variáveis que acrescentam informação complementar à tarefa de classificação (GALVÃO *et al.*, 2024).

2.5 Mecanismos de Otimização Combinatória

Com o problema codificado na matriz Q , o objetivo passa a ser encontrar o vetor binário que minimiza a função de custo, dado por $x^* = \arg \min E(x)$. Como a otimização combinatória em espaços de alta dimensão é um problema NP-difícil, o espaço de busca apresenta diversos mínimos locais. Algoritmos clássicos, como métodos gulosos ou de descida de gradiente, frequentemente convergem de forma prematura para essas soluções subótimas, falhando em alcançar o ótimo global (YE *et al.*, 2026; MARTÍNEZ-GARCÍA *et al.*, 2025).

Para superar essa limitação computacional, utiliza-se a meta-heurística estocástica *Simulated Annealing* (SA) (MARTÍNEZ-GARCÍA *et al.*, 2025; SUN *et al.*, 2025). O algoritmo introduz flutuações térmicas simuladas para explorar o espaço de soluções, permitindo a aceitação temporária de transições para configurações de maior energia (soluções piores). Essa aceitação probabilística é avaliada pelo critério de Metropolis, cujo comportamento é governado pela distribuição de Boltzmann (KIRKPATRICK *et al.*, 1983):

$$P(\Delta E, T) = \exp\left(-\frac{\Delta E}{T}\right) \quad (2.8)$$

onde ΔE representa a variação de energia entre o estado atual e o candidato, e T denota a temperatura corrente do sistema. À medida em que o parâmetro de temperatura decresce conforme um cronograma de resfriamento (*cooling schedule*), a probabilidade de aceitar transições desfavoráveis é progressivamente reduzida. Esse mecanismo viabiliza uma exploração ampla do espaço de soluções nas etapas iniciais e o refinamento local em direção ao mínimo global nas fases de baixa temperatura (KIRKPATRICK *et al.*, 1983).

Embora o *Quantum Annealing* (QA) físico represente uma alternativa teórica ao substituir flutuações térmicas por tunelamento quântico para transpor barreiras de potencial (KADOWAKI; NISHIMORI, 1998), sua aplicação prática enfrenta as restrições da era NISQ (*Noisy Intermediate-Scale Quantum*) (BARRETO *et al.*, 2024). Os dispositivos atuais sofrem com ruídos ambientais, tempos reduzidos de coerência e limitações na conectividade topológica dos qubits lógicos necessários para mapear problemas de alta dimensionalidade (YE *et al.*, 2026; BARRETO *et al.*, 2024).

Diante dessas restrições de hardware, o uso do *Simulated Annealing* associado à modelagem QUBO consolida-se como uma abordagem quântico-inspirada robusta (GALVÃO *et al.*, 2024). Essa estratégia possibilita explorar a estrutura matricial quadrática sem os descartes topológicos ou esparsificações impostas pelos processadores físicos atuais, garantindo a reprodutibilidade da convergência para estados de menor energia em infraestruturas computacionais tradicionais (GALVÃO *et al.*, 2024).

2.6 Algoritmos de Classificação Para Avaliação de Desempenho


Para validar a eficácia dos subconjuntos de características selecionados, é necessário empregar algoritmos de classificação que possam quantificar o desempenho preditivo. A validação multimodelo garante que o ganho de desempenho seja diretamente resultante da qualidade

informacional do subconjunto selecionado.

2.6.1 Random Forest

O *Random Forest* é um algoritmo de aprendizado de máquina baseado na construção de um conjunto de árvores de decisão utilizadas de forma conjunta para realizar tarefas de classificação ou regressão. O método introduz aleatoriedade em duas etapas principais. Inicialmente, aplica o método de *bagging*, que consiste em sortear repetidamente exemplos com reposição até que a nova amostra atinja o mesmo tamanho do conjunto de treinamento original, fazendo com que cada árvore seja treinada com uma amostra *bootstrap* distinta. Em seguida, durante a construção de cada árvore, apenas um subconjunto aleatório das variáveis preditoras é considerado em cada divisão dos nós, reduzindo a correlação entre as árvores e aumentando a capacidade de generalização do modelo. Para problemas de classificação, a predição final é obtida por votação majoritária entre todas as árvores, enquanto, em tarefas de regressão, utiliza-se a média das predições individuais (BREIMAN, 2001).

Figura 6 – Random Forest Simplificado.




Fonte: Adaptado de Oztornaci *et al.* (2024)

A Figura 6 apresenta uma representação simplificada do funcionamento do algoritmo. Inicialmente, diferentes amostras *bootstraps* são gerados a partir da base de dados original. Cada subconjunto é utilizado para treinar uma árvore de decisão independente, produzindo uma predição individual. Ao final, as respostas de todas as árvores são agregadas para produzir a predição final.

2.6.2 *K-Nearest Neighbors (KNN)*

O *K-Nearest Neighbors (KNN)* é um algoritmo de aprendizado supervisionado utilizado para tarefas de classificação e regressão. O *KNN* baseia suas previsões na similaridade entre os exemplos do conjunto de dados. Seu funcionamento consiste em armazenar instâncias de treinamento e, durante a etapa de predição, identificar os *k*-vizinhos mais próximos da nova observação de acordo com uma métrica de distância previamente definida. Em problemas de classificação, a classe atribuída ao novo exemplo é determinada pela classe predominante entre os *k*-vizinhos selecionados; já em problemas de regressão, a predição é obtida a partir da média ou de uma combinação ponderada dos valores observados dos vizinhos mais próximos (ZHANG, 2016).

Figura 7 – Ilustração do Funcionamento do Algoritmo *KNN*.




Fonte: Zhang (2016)

A Figura 7 ilustra como funciona o sistema de decisão do algoritmo em um cenário de classificação multiclasse. A figura central representa a nova amostra a ser classificada, enquanto as figuras ao redor correspondem às instâncias de treinamento. A distância entre a figura central e as demais é calculada, e os *k*-vizinhos mais próximos são identificados. A classe predominante entre esses vizinhos é então atribuída à nova amostra.

2.6.3 Support Vector Machine (SVM)

O *Support Vector Machine* (SVM) é um algoritmo de aprendizado supervisionado utilizado em tarefas de classificação e regressão. Para conjuntos de dados linearmente separáveis, o SVM procura encontrar um hiperplano que maximize a margem entre as classes. Diante de conjuntos que apresentam ruído ou sobreposição, o que impede uma separação geométrica perfeita, o algoritmo introduz o conceito de variáveis de folga. As variáveis de folga permitem que algumas amostras violem a margem de separação, equilibrando a largura da margem e a quantidade de erros de classificação admitidos. Quando a separação linear não é suficiente para distinguir as classes, o SVM aplica o método de *kernel*, mapeando os vetores de entrada para um espaço de maior dimensão onde a separabilidade linear se torna viável (LORENA; CARVALHO, 2007).

Figura 8 – SVM Simplificado.




Fonte: Adaptado de Oztornaci *et al.* (2024)

A Figura 8 apresenta uma representação simplificada do funcionamento do algoritmo em um problema de classificação binária. O SVM busca identificar o hiperplano que separa as duas classes, representadas pelos pontos azuis e vermelhos. A margem é definida como a distância entre o hiperplano e os pontos mais próximos de cada classe, conhecidos como vetores de suporte. O objetivo do algoritmo é maximizar essa margem, garantindo uma melhor generalização do modelo para novos dados.

2.6.4 eXtreme Gradient Boosting (XGBoost)

O *eXtreme Gradient Boosting (XGBoost)* é um algoritmo de aprendizado supervisionado baseado em árvores de decisão impulsionadas por gradiente. Seu funcionamento consiste em construir sequencialmente um conjunto de árvores, em que cada novo modelo é treinado para corrigir os erros cometidos pelas árvores previamente gerados. O *XGBoost* utiliza o princípio do *gradient boosting*, adicionando iterativamente funções que minimizam uma função de perda por meio de aproximações baseadas em gradiente. Para a predição, as saídas produzidas por todas as árvores são combinadas de forma aditiva. Em problemas de regressão, as somas das contribuições das árvores fornece diretamente o valor previsto; já em tarefas de classificação, essa soma é transformada em probabilidades por funções adequadas, como função logística para classificação binária, sendo a classe final determinada pela maior probabilidade estimada (CHEN; GUESTRIN, 2016).

Figura 9 – XGBoost Simplificado.




Fonte: Adaptado de Oztornaci *et al.* (2024)

A Figura 9 ilustra o aprendizado em cascata do algoritmo. Inicialmente, uma árvore de decisão é treinada para realizar a predição. Em seguida, os erros residuais dessa árvore são utilizados como alvo para treinar a próxima árvore, que busca corrigir as falhas do modelo anterior. Esse processo é repetido iterativamente, com cada nova árvore contribuindo para melhorar a precisão do modelo final.

2.6.5 Categorical Boosting (CatBoost)

O *Categorical Boosting (CatBoost)* é um algoritmo de aprendizado supervisionado baseado na técnica de *gradient boosting* sobre árvores de decisão, desenvolvido para lidar de forma eficiente com atributos categóricos. Seu funcionamento consiste em construir sequencialmente um conjunto de árvores, em que cada novo modelo busca corrigir os erros cometidos pelos métodos gerados nas iterações anteriores. Entretanto, o *CatBoost* introduz mecanismos específicos para reduzir o viés durante o treinamento e melhorar o tratamento de variáveis categóricas. Na fase de predição, as contribuições produzidas por todas as árvores são agregadas de forma aditiva para gerar a resposta final do modelo. Em problemas de regressão, o valor previsto corresponde à soma de todas as contribuições das árvores, enquanto em tarefas de classificação essa soma é convertida em probabilidades por funções apropriadas (PROKHORENKOVA *et al.*, 2018).

Figura 10 – CatBoost Simplificado.



Fonte: GeeksforGeeks (2025)


A Figura 10 apresenta uma representação simplificada do algoritmo. Nela pode-se observar a adição em sequência de novas árvores de decisão, cada uma treinada para corrigir os erros do modelo anterior. O processo continua até que um número predeterminado de árvores seja alcançado ou até que a melhoria no desempenho do modelo se torne insignificante.

2.6.6 Optimum-Path Forest (OPF)

O *Optimum-Path Forest (OPF)* é um algoritmo de aprendizado supervisionado baseado em grafos, utilizado em tarefas de classificação e segmentação. Nesse método, cada amostra do conjunto de dados é representada como um nó de um grafo completo, cujas arestas são ponderadas por uma medida de distância entre as amostras. Durante o treinamento, é identificado

um conjunto de protótipos que atuam como raízes de árvores de caminhos ótimos, formando uma floresta que particiona o grafo. Na etapa de classificação, cada nova amostra é conectada ao grafo de treinamento e atribuída à árvore cujo caminho ótimo apresenta o menor custo, herdando a classe do respectivo protótipo (PAPA *et al.*, 2009).

Figura 11 – Algoritmo OPF.




Fonte: Papa *et al.* (2009)

A Figura 11 demonstra o funcionamento do algoritmo. O OPF modela o espaço de características como um grafo, no qual cada amostra representa um nó e as arestas que os conectam são ponderadas pela distância geométrica entre as instâncias (Quadro a). O processo de treinamento do algoritmo (Quadro b) consiste em identificar os protótipos, para atuar como raízes de uma floresta. A partir dessas raízes, o algoritmo computa caminhos ótimos que minimizam uma função de custo predefinida, inundando o grafo e conquistando os nós adjacentes. Ao término dessa etapa, cada amostra de treinamento é associada a uma tupla contendo o custo de seu caminho e o rótulo da classe da raiz que a conquistou, formando um conjunto de árvores de caminhos ótimos. Durante a fase de teste (Quadro c), uma nova observação desconhecida é inserida no espaço de características. O modelo estabelece arestas virtuais entre essa nova amostra e os nós da floresta já construída, computando as distâncias correspondentes. A classificação ocorre de forma determinística (Quadro d): a nova amostra é conquistada pelo nó de treinamento que lhe oferecer o caminho com o menor custo final, herdando assim o rótulo de sua respectiva raiz.

2.7 Validação Cruzada

A validação cruzada é uma técnica empregada para avaliar a capacidade de modelos preditivos. Nesse método, o conjunto de dados é dividido em k subconjuntos mutuamente exclusivos, denominados *folds*. Em cada iteração, um dos *folds* é utilizado para validação, enquanto os $k - 1$ subconjuntos restantes são utilizados para treinamento do modelo. O procedimento é repetido até que todos os *folds* tenham sido usados exatamente uma vez como conjunto de validação. Ao final, as métricas de desempenho obtidas em cada iteração são agregadas, geralmente por meio da média, produzindo uma estimativa da capacidade preditiva do modelo (NTI *et al.*, 2021).

Figura 12 – Validação Cruzada k -fold.



Fonte: Scikit-learn Developers (2025).

A Figura 12 ilustra o processo de validação cruzada k -fold. O conjunto de dados é dividido em 5 subconjuntos, e o modelo é treinado e avaliado 5 vezes, cada vez utilizando um subconjunto diferente para validação. Ao final, as métricas de desempenho são combinadas para fornecer uma estimativa da capacidade preditiva do modelo.

2.8 Normalização Z-Score

A normalização dos dados consiste em transformar os atributos para uma escala comum, reduzindo os efeitos decorrentes de diferenças de magnitude entre as variáveis. Entre as técnicas mais utilizadas, destaca-se a padronização Z-Score, que transforma cada atributo para apresentar média zero e desvio padrão unitário.

A transformação é dada por:

$$z = \frac{x - \mu}{\sigma} \quad (2.9)$$

, em que x representa o valor original do atributo, μ corresponde à média da variável e σ ao seu desvio padrão.

A padronização é particularmente importante para algoritmos sensíveis à escala dos dados, como Support Vector Machines (SVM), K-Nearest Neighbors (KNN) e modelos lineares regularizados, uma vez que impede que atributos com maiores amplitudes exerçam influência desproporcional durante o processo de treinamento (HASTIE *et al.*, 2009; BISHOP, 2006).

2.9 Grid Search

O *Grid Search* é uma técnica de otimização de hiperparâmetros utilizado em aprendizado de máquina. Seu funcionamento consiste em definir previamente um conjunto de valores candidatos para cada hiperparâmetro e avaliar exaustivamente todas as combinações possíveis entre esses valores. Para cada configuração gerada, o modelo é treinado e avaliado segundo uma métrica de desempenho, permitindo identificar a combinação que produz os melhores resultados (YU; ZHU, 2020).

Na prática, o *Grid Search* é frequentemente combinado com técnicas de validação cruzada, de modo que cada combinação de hiperparâmetros seja avaliada em diferentes partições do conjunto de treinamento. Ao final da busca, seleciona-se a configuração que obtiver o melhor desempenho médio segundo a métrica adotada, reduzindo a influência de variações decorrentes de uma única divisão dos dados (YU; ZHU, 2020).

2.10 Teste Estatístico de Wilcoxon

O teste de Wilcoxon é um método estatístico não paramétrico utilizado para comparar duas amostras pareadas. Esse teste não exige a suposição de normalidade dos dados, sendo adequado para a comparação de algoritmos de aprendizado de máquina cujas métricas de desempenho podem apresentar distribuições desconhecidas ou não gaussianas. O teste baseia-se nas diferenças observadas entre pares de resultados, ordenando os valores absolutos dessas diferenças e atribuindo postos (*ranks*). Em seguida, os postos associados às diferenças positivas e negativas são comparados para verificar se existe evidência estatística de que um método apresente desempenho superior ao outro (DEMSAR, 2006).

No teste de Wilcoxon, a hipótese nula (H_0) estabelece que não existe diferença estatisticamente significativa entre os desempenhos dos dois métodos comparados, enquanto a hipótese alternativa (H_A) afirma que essa diferença existe. A decisão é tomada a partir do valor- p , comparado ao nível de significância previamente definido, geralmente $\alpha = 0,05$. Quando $p < \alpha$, rejeita-se H_0 , indicando evidências estatísticas de diferença entre os métodos. Caso contrário, não há evidências suficientes para rejeitar a hipótese nula, sugerindo que as diferenças observadas podem ser atribuídas à variabilidade amostral (DEMSAR, 2006).

2.11 Métricas de Avaliação

As métricas de avaliação são utilizadas para quantificar o desempenho de modelos de aprendizado de máquina, permitindo analisar diferentes aspectos da capacidade preditiva dos algoritmos. Neste contexto, apresentam-se a seguir os termos básicos que fundamentam parte das métricas adotadas nesse trabalho:

- **Verdadeiro Positivo (TP):** Quantidade de instâncias positivas corretamente classificadas como positivas pelo modelo.
- **Verdadeiro Negativo (TN):** Quantidade de instâncias negativas corretamente classificadas como negativas pelo modelo.
- **Falso Positivo (FP):** Quantidade de instâncias negativas incorretamente classificadas como positivas pelo modelo.
- **Falso Negativo (FN):** Quantidade de instâncias positivas incorretamente classificadas como negativas pelo modelo.

2.11.1 Acurácia

A acurácia representa a proporção de predições corretas realizadas pelo modelo em relação ao número total de observações avaliadas. Embora seja uma métrica simples e intuitiva, seu uso isolado pode ser inadequado em conjuntos de dados desbalanceados, nos quais uma classe é significativamente mais frequente que as outras. A fórmula a seguir descreve o cálculo da acurácia:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.10)$$

2.11.2 *Precisão*

A precisão mede a proporção de exemplos corretamente classificados como positivos dentre todas as observações preditas como positivas. A fórmula a seguir descreve o cálculo da precisão:

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (2.11)$$

2.11.3 *Recall*

O *recall* mede a capacidade do modelo de identificar corretamente os exemplos positivos presentes no conjunto de dados. A fórmula a seguir descreve o cálculo do *recall*:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.12)$$

2.11.4 *F1-Score*

O *F1-score* combina precisão e *recall* em uma única medida por meio de sua média harmônica. Tem como objetivo fornecer uma avaliação equilibrada do modelo, sendo útil em cenários com classes desbalanceadas ou quando é necessário considerar simultaneamente a redução de falsos positivos e falsos negativos. A fórmula a seguir descreve o cálculo do *F1-score*:

$$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (2.13)$$

2.11.5 *Área Sob a Curva ROC (AUC-ROC)*

A área sob a curva ROC avalia a capacidade discriminativa do classificador ao considerar diferentes limiares de decisão. Essa métrica quantifica o quão bem o modelo consegue distinguir exemplos pertencentes a classes distintas. Diferente das demais métricas, a AUC-ROC não possui uma fórmula fechada simples, sendo calculada pela integração numérica da curva ROC ao longo de diferentes limiares de decisão (FAWCETT, 2006).

3 TRABALHOS RELACIONADOS

Neste capítulo, apresentamos uma revisão da literatura recente sobre o uso de formulações QUBO e Annealing na seleção de características em problemas de classificação binária, destacando como diferentes autores têm lidado com os desafios de relevância e redundância.

Galvão *et al.* (2024) investigam o problema da alta dimensionalidade em dados financeiros voltados à previsão de inadimplência, utilizando uma base composta por 5.889 atributos. Os autores destacam que a presença de características irrelevantes e redundantes aumenta o custo computacional e pode comprometer o desempenho dos modelos de classificação. Para contornar esse problema, a seleção de atributos foi formulada como um problema *QUBO* e resolvida por meio dos algoritmos *Q-Boosting* e *Q-Correlation*, executados no simulador de *Quantum Annealing* Kuatomu. Os resultados demonstraram ganhos no desempenho dos classificadores após a etapa de seleção de características. Entre os métodos avaliados, o *Q-Correlation* alcançou a maior acurácia (0,931), mantendo 3.048 variáveis no conjunto selecionado. Já o *Q-Boosting* promoveu uma redução muito mais acentuada, selecionando apenas uma característica e obtendo acurácia de 0,919. De acordo com o critério AIC, a solução obtida pelo *Q-Boosting* apresentou o melhor compromisso entre desempenho e complexidade do modelo.

Martínez-García *et al.* (2025) propõem o algoritmo *SA-FDR*, um método de seleção de características do tipo *wrapper* baseado em *Simulated Annealing* (SA). Com o objetivo de reduzir o custo computacional associado ao treinamento repetido de classificadores durante a busca, os autores utilizam a Razão Discriminante de Fisher (FDR) como medida de avaliação dos subconjuntos gerados. O método foi avaliado em nove bases de dados públicas, incluindo o conjunto *Loan Default*, composto por 103.302 instâncias e 397 atributos. Em termos de redução de dimensionalidade, o SA-FDR alcançou modelos mais compactos em diversos cenários. Por exemplo, na base *Spambase*, o algoritmo utilizou 23,4 atributos para atingir uma AUC de 0,969, enquanto o Lasso, embora tenha alcançado uma AUC ligeiramente superior (0,971), exigiu 37,6 atributos.

Nau *et al.* (2025) avaliam o uso de *Quantum Annealing* (QA) em hardware quântico real, utilizando o sistema *D-Wave Advantage_system4.1* para seleção de características em conjuntos de imagens do benchmark *MedMNIST*. O problema é formulado como um modelo *QUBO* baseado em Informação Mútua, buscando maximizar a relevância dos atributos selecionados e minimizar a redundância entre eles. Devido às limitações de conectividade do hardware, os autores empregam três estratégias principais: redução da dimensionalidade por agrupamento

espacial de pixels em blocos 2×2 , eliminação de acoplamentos de menor magnitude por meio de um limiar de corte e substituição da restrição quadrática tradicional por uma penalidade linear no modelo de *Ising*. Os experimentos foram conduzidos em imagens de 28×28 pixels e avaliados por meio do Erro Quadrático Médio obtido por decodificadores convolucionais de reconstrução. Os resultados obtidos por Nau *et al.* (2025) utilizam o Erro Quadrático Médio (MSE) como métrica de avaliação da reconstrução das imagens. Eles indicam que os subconjuntos de pixels selecionados por *Quantum Annealing* (QA) apresentam bom desempenho em bases com imagens previamente alinhadas, superando o baseline supervisionado Lasso. Entretanto, os autores observam redução da capacidade de generalização em conjuntos mais heterogêneos, nos quais o QA não superou o baseline de subamostragem uniforme.

Ye *et al.* (2026) propõem uma abordagem que envolve o desenvolvimento de um modelo que integra, de forma conjunta, a seleção de características e o ajuste de parâmetros de uma regressão logística (IFSLR). Para contornar a complexidade NP-Difícil dessa otimização simultânea, o trabalho reformula o problema em modelos de *QUBO* através da discretização de variáveis contínuas e expansões de Taylor. A metodologia adota uma arquitetura híbrida que combina o aprendizado por reforço (Q-Learning) e uma Máquina de Ising Coerente (CIM) para explorar o espaço de soluções. Os resultados experimentais, validados nos conjuntos de dados *German credit* e *Wisconsin diagnostic breast cancer* (WDBC), demonstram que o acoplamento do modelo linear clássico com a formulação QUBO mitiga problemas de *overfitting*, funcionando como uma forma de regularização que preserva ou melhora a capacidade de generalização no conjunto de teste em comparação ao modelo contínuo original. Na base *German credit*, o método proposto (*QUBO-L*) obteve uma acurácia de 0,8143 e um *F1-score* de 0,6521, superando a regressão clássica com penalização *Lasso-LR* em 10,04% na acurácia e 17,09% no *F1-score* global, utilizando um subconjunto 20% menor de atributos. Similarmente, no conjunto de dados de câncer de mama (WDBC), o modelo selecionou de forma ótima apenas 6 características e alcançou acurácia de 0,9649, *F1-score* de 0,9346 e *AUC* de 0,9941, superando o desempenho do *Lasso-LR* que exigiu a retenção de 10 variáveis.

Giobergia *et al.* (2025) investigam a seleção de características para sistemas de recomendação baseados em conteúdo, formulando o problema através de uma matriz *QUBO*. A abordagem modela a otimização como um problema de relevância e redundância, a diagonal principal recebe o simétrico da importância dos atributos extraída de um comitê de *Random Forest*, enquanto as interações quadráticas capturam o valor absoluto da correlação de Pearson

entre as representações dos usuários. Avaliado sobre duas matrizes de descritores de conteúdo de 100 e 400 atributos, o método *RF-QUBO* superou as estratégias de amostragem aleatória e linhas de base colaborativas na métrica nDCG@10.

Shaikh *et al.* (2025) propõem uma abordagem de seleção de características inspirada em computação quântica para a tarefa de *Learning to Rank* (LTR), validada na coleção MQ2007. O problema é modelado como um Modelo Quadrático Binário (BQM), no qual a relevância dos atributos é mensurada pela Informação Mútua (MI) com o rótulo de relevância, enquanto a redundância mútua é penalizada através da Informação Mútua Condicional (CMI) atrelada ao rótulo. Para fixar a cardinalidade do subconjunto em $k = 10$ atributos, os autores aplicam uma penalidade branda de peso $\alpha = 10,0$. Submetidos a classificadores *RankSVM*, os vetores induzidos via *Quantum Annealing* (QPU da D-Wave) atingiram um pico de nDCG@10 de 0,4409, superando a versão induzida por *Simulated Annealing* clássico (0,4212) com uma redução do tempo de otimização de aproximadamente 14 vezes.

Molino-Piñar *et al.* (2025) propõem uma abordagem de seleção de características baseada em *Quantum Annealing* (D-Wave) para otimizar modelos de ranqueamento (*LambdaMART*) na coleção MQ2007. O problema é modelado como um *MIQUBO*, balanceando a relevância individual pela Informação Mútua e a redundância via Informação Mútua Condicional. O grande diferencial da engenharia reside no pós-processamento das 100 leituras brutas de energia devolvidas pela QPU: os autores desenvolvem duas estratégias de agregação para converter a frequência de aparecimento e as energias escalares em um ranqueamento unificado de atributos. Além disso, para estipular o tamanho ideal do subconjunto, ajustaram uma parábola sobre os picos de energia mínima, estipulando analiticamente o ponto ótimo em $k = 21$ características através da fórmula do vértice. O subconjunto retornado pelo recozimento quântico retendo 21 variáveis atingiu o pico de nDCG@10 de 0,4580.

De forma geral, os trabalhos analisados evidenciam a ampla adoção de formulações *QUBO* para a seleção de características, mas divergem nas estratégias de modelagem e nos domínios de aplicação. Estudos como os de Nau *et al.* (2025) e Giobergia *et al.* (2025) concentram-se em nichos específicos, como imagens médicas e sistemas de recomendação, respectivamente. Por outro lado, pesquisas como as de Martínez-García *et al.* (2025) e Ye *et al.* (2026) optam por validações abrangentes em bases de dados de múltiplos domínios, demonstrando a capacidade de generalização de suas abordagens. Em relação à formulação matemática, observa-se a predominância da Informação Mútua (MI) e de suas variantes para capturar a dependência entre

atributos e a classe alvo. Contudo, há exceções na literatura que obtêm a relevância a partir de modelos previamente treinados, como a importância extraída de algoritmos de *Random Forest*, ou que adotam formulações embarcadas (*embedded*) baseadas em aproximações de Taylor para a discretização de pesos. Outra diferença metodológica reside nas estratégias de comparação e de avaliação. Trabalhos voltados para a experimentação em *hardware* quântico, utilizam o algoritmo clássico *Simulated Annealing* como uma linha de base para atestar e comparar a viabilidade de execução nas Unidades de Processamento Quântico (QPU) da *D-Wave*. Em contrapartida, estudos focados na proposição de novos motores matemáticos de otimização submetem suas formulações a comparações contra algoritmos clássicos de seleção de características. Nau *et al.* (2025), Martínez-García *et al.* (2025) e Ye *et al.* (2026), por exemplo, utilizam técnicas de Eliminação Recursiva de Características (RFE), modelos de penalização regularizada (Lasso, Lasso-LR) e Análise de Componentes Principais Esparsa (SPCA) como *baselines* tradicionais. No que tange a avaliação, observa-se o emprego recorrente de estratégias de validação experimental e métricas de dispersão para aferir a estabilidade dos resultados. Entretanto, a aplicação de testes estatísticos formais ainda é pouco frequente.

Apesar dos avanços observados, algumas limitações permanecem presentes. A dependência de infraestruturas quânticas específicas impõe restrições físicas que frequentemente exigem a esparsificação das matrizes ou descartes topológicos de interações redundantes para que o problema se adeque à conectividade do chip, dificultando a reprodutibilidade dos experimentos em ambientes convencionais.

Nesse contexto, o presente trabalho busca contribuir para essa discussão ao estabelecer uma formulação *QUBO* fundamentada no critério *mRMR*, utilizando a Informação Mútua para estimar a relevância dos atributos e a correlação de Spearman para modelar as penalidades de redundância entre pares de características. Diferentemente das abordagens que dependem de *hardware* quântico ou de otimizações iterativas acopladas ao classificador, a varredura combinatória é realizada integralmente por meio do *Simulated Annealing*. Essa arquitetura permite utilizar a matriz *QUBO* sem a necessidade de adaptações impostas por restrições de conectividade de *hardware* quântico, favorecendo sua reprodutibilidade e aplicabilidade prática.

Uma comparação resumida entre os trabalhos relacionados e este estudo encontra-se na Tabela 1.

Tabela 1 – Comparação entre os trabalhos relacionados e a abordagem proposta

Trabalho	Base de Dados	Relevância	Redundância	HQ?	QUBO?	SA?	Classif. Clássico	Teste Estat.
Galvão et al. (2024)	Cibersegurança/Finanças	Pearson/SVM	Pearson	Não	Sim	Sim	×	×
Martínez-García et al. (2025)	Benchmarks públicos	Não se Aplica	Não se Aplica	Não	Não	Sim	✓	×
Nau et al. (2025)	Imagens Médicas	IM	IM Cruzada	Sim	Sim	Não	✓	×
Ye et al. (2026)	Dados Hiperdimensionais	Regressão Logística	Não se Aplica	Sim	Sim	Não	✓	×
Giobergia et al. (2025)	Imagens Médicas	Random Forest	Pearson	Não	Sim	Sim	×	×
Shaikh et al. (2025)	UCI e Microarray	IM	IM Condicional	Sim	Sim	Sim (baseline)	×	×
Molino-Piñar et al. (2025)	MQ2007 LETOR	IM	IM Condicional	Sim	Sim	Sim (baseline)	×	×
Este Trabalho	Ovarian / Colon / Prostate	IM	Spearman	Não	Sim	Sim	✓	✓

*IM = Informação Mútua, *HQ = Hardware Quântico. *SA = Simulated Annealing.

Fonte: Elaborada pelo autor


4 METODOLOGIA

Neste capítulo, é apresentada a metodologia que será empregada para a seleção de características em problemas de classificação binária. A metodologia adotada consiste em uma abordagem baseada na Otimização Quadrática Binária Irrestrita (QUBO) inspirada no critério mRMR (Minimum Redundancy Maximum Relevance). Devido à indisponibilidade de hardware quântico real de grande escala, a minimização de energia do sistema é emulada por meio de uma meta-heurística de *Simulated Annealing* (SA).

4.1 Visão Geral

A metodologia empregada neste trabalho, incluindo suas principais etapas, está ilustrada na Figura 13.

Figura 13 – Visão geral da metodologia adotada.



Fonte: Elaborado pelo autor.

Inicialmente, estabelece-se o bloco de aquisição do conjunto de dados, composto por três *datasets* distintos. Em seguida, os dados serão submetidos ao processo de validação

cruzada do tipo K-Fold. Na sequência, inicia-se a etapa de seleção de características, nas quais os subconjuntos de dados serão submetidos aos diferentes métodos de seleção de características. Serão avaliadas abordagens pertencentes às categorias *Filter* (*Anova F-Score*), *Wrapper* (*Recursive Feature Elimination with Cross-Validation*) e *Embedded* (Lasso), além da formulação QUBO. A matriz QUBO é então submetida ao algoritmo Simulated Annealing para obtenção do subconjunto de características para treinamento dos classificadores. O conjunto de dados também será submetido a uma etapa de treinamento e avaliação sem a aplicação de seleção de características, servindo como referência para comparação com os métodos avaliados.

Os subconjuntos gerados serão utilizados para treinar os algoritmos *Random Forest*, *K-Nearest Neighbors* (KNN), *Support Vector Machine* (SVM), *XGBoost* e *CatBoost*. O desempenho de cada modelo é posteriormente avaliado sobre o conjunto de teste correspondente ao fold atual.

A avaliação é conduzida por meio das métricas de acurácia, precisão, recall, F1-Score e área sob a curva ROC (AUC-ROC). Ao final da validação cruzada, os resultados obtidos em todos os folds serão agregados por meio da média e do desvio padrão, permitindo uma análise da estabilidade dos modelos. Adicionalmente, aplica-se o teste estatístico não paramétrico de Wilcoxon para verificar a existência de diferenças estatisticamente significativas entre os métodos de seleção de características avaliados.

Por fim, os métodos serão comparados considerando o desempenho preditivo, a redução dimensional obtida e os resultados do teste estatístico de Wilcoxon.

4.2 Conjuntos de Dados

Para testar cenários de média e alta dimensionalidade, foram selecionadas três bases de dados amplamente utilizadas na seleção de características: *Ovarian Cancer Proteomic Dataset*, *Colon Cancer* e *Prostate Tumor*. Essas bases representam problemas de classificação binária com elevado número de características e uma baixa amostragem.

A Tabela 2 apresenta um resumo das principais características dos conjuntos utilizados.

Tabela 2 – Características dimensionais dos conjuntos de dados utilizados.

Base de Dados	Amostras (N)	Atributos (M)	Classes
Ovarian	253	1.513	2
Colon Cancer	62	2.000	2
Prostate Tumor	102	6.033	2

Fonte: Elaborado pelo autor.

4.2.1 *Ovarian Cancer Proteomic Dataset*

O conjunto *Ovarian Cancer Proteomic Dataset* é composto por perfis proteômicos obtidos por meio de análises de espectrometria de massa em amostras biológicas de pacientes com câncer de ovário e indivíduos saudáveis. Cada amostra possui uma anotação supervisionada binária, indicando a condição clínica correspondente. Por se tratar de dados proteômicos de alta dimensionalidade, o conjunto apresenta elevada redundância e presença de ruído, sendo frequentemente utilizado como referência em estudos de seleção de características e aprendizado de máquina aplicado à bioinformática.

4.2.2 *Colon Cancer*

O conjunto de dados *Colon Cancer* foi originalmente construído a partir de amostras de tecido do cólon humano, contendo medições de expressão gênica obtidas por meio de técnicas de *microarray*. Cada amostra é rotulada de forma supervisionada, indicando a presença de tecido tumoral ou tecido saudável, caracterizando um problema de classificação binária. Devido à elevada quantidade de atributos em relação ao número reduzido de amostras, este conjunto apresenta forte desequilíbrio dimensional, sendo frequentemente utilizado para avaliação de métodos de seleção de características.

4.2.3 *Prostate Tumor*

O conjunto Prostate Tumor consiste em dados de expressão gênica obtidos a partir de amostras de tecido prostático, incluindo tanto indivíduos saudáveis quanto pacientes diagnosticados com câncer de próstata. Trata-se de um problema de classificação binária supervisionada, no qual cada amostra é associada a um rótulo clínico. Este conjunto possui uma alta dimensionalidade, contendo milhares de atributos moleculares e um número relativamente reduzido de amostras, o que o torna adequado para avaliação de técnicas de seleção de características.

4.3 Validação Cruzada K-Fold

Para a condução dos experimentos, será empregada a validação cruzada estratificada do tipo K-Fold com $K = 10$. Nessa estratégia, o conjunto de dados é particionado em dez subconjuntos (folds), preservando a proporção original das classes em cada partição. A cada iteração do processo, um dos folds é reservado para teste, enquanto os nove folds restantes são utilizados para treinamento do modelo.

Esse procedimento é repetido dez vezes, de forma que cada partição seja utilizada exatamente uma vez como conjunto de teste. Dessa forma, obtém-se uma estimativa mais robusta do desempenho dos modelos, reduzindo a dependência de uma única divisão dos dados e mitigando possíveis vieses decorrentes de particionamentos específicos. Além disso, a estratificação garante que todas as classes estejam representadas de forma equilibrada em cada fold.

4.4 Processamento em cada *fold*

Após a definição dos conjuntos de treinamento e teste por meio da validação cruzada estratificada, cada iteração será executada de forma independente. Em cada fold, serão realizadas as etapas de seleção de características, otimização de hiperparâmetros, treinamento dos classificadores e avaliação de desempenho. Essa estratégia garante que todas as decisões do processo de modelagem sejam tomadas exclusivamente com base nos dados de treinamento da iteração corrente, preservando a independência do conjunto de teste.

4.4.1 Normalização dos Dados

Em cada fold, os atributos do conjunto de treinamento serão padronizados por meio da transformação Z-Score. Os parâmetros de média e desvio padrão serão estimados exclusivamente a partir dos dados de treinamento e posteriormente aplicados ao conjunto de teste correspondente, evitando vazamento de informação.

A normalização é necessária para garantir que atributos com diferentes escalas não influenciem de forma desproporcional os algoritmos de classificação e os métodos de seleção empregados.

4.4.2 Geração de Subconjuntos de Características

Nessa etapa será realizada a geração dos conjuntos de características referentes às abordagens expostas nesse trabalho.

4.4.2.1 ANOVA *F-score* (Filtro)

A filtragem estatística será realizada por meio do teste ANOVA *F-score*, avaliando a capacidade discriminativa individual de cada atributo em relação à variável alvo. Utilizando a implementação da biblioteca `scikit-learn` via função `f_classif`. Para determinar o tamanho ideal do subconjunto, a proporção de colunas retidas será tratada como um hiperparâmetro otimizado dinamicamente dentro do *Grid Search* de cada classificador através da classe `SelectPercentile`, permitindo que o próprio estimador defina a quantidade de atributos mais relevantes para a sua decisão.

4.4.2.2 Recursive Feature Elimination with Cross-Validation (Wrapper)

Como representante do tipo *wrapper* será utilizado o algoritmo *Recursive Feature Elimination with Cross-Validation* (RFECV) através do pacote `sklearn.feature_selection`. Para guiar a avaliação dos subconjuntos, adotou-se como estimador base o algoritmo *Random Forest* (`n_estimators=100`, `random_state=42`), com `step=0.05`. O número de atributos selecionados será definido automaticamente pelo RFECV K_{rfe} correspondente ao melhor desempenho observado na validação cruzada interna.

4.4.2.3 Lasso (Embedded)

A seleção embarcada (*embedded*) será realizada por meio de uma Regressão Logística com regularização L_1 , utilizando a classe `LogisticRegressionCV`. Durante o treinamento, diferentes valores do parâmetro de regularização C serão avaliados por validação cruzada interna, sendo selecionada a configuração com melhor desempenho. Como a penalização L_1 induz esparsidade nos coeficientes do modelo, atributos associados a coeficientes reduzidos a zero serão descartados. Dessa forma, o subconjunto final será composto apenas pelas características que permanecerem com coeficientes diferentes de zero após o ajuste do classificador.

4.4.2.4 QUBO + Simulated Annealing

A abordagem proposta modela a seleção de características como um problema de otimização QUBO, no qual cada variável binária representa a decisão de selecionar ou não um atributo. A matriz quadrada (Q), de dimensão $(M \times M)$, é construída associando os elementos da diagonal principal ((Q_{ii})) à relevância negativa individual das características, estimada por meio da Informação Mútua (IM) calculada pela função `mutual_info_classif` do pacote `sklearn.feature_selection`. Os elementos fora da diagonal ((Q_{ij})) representam a redundância entre pares de atributos, sendo obtidos a partir da correlação de Spearman calculada pela função `corr()` da biblioteca `pandas` com o parâmetro `method="spearman"`.

Após a construção da matriz QUBO, a busca pelo subconjunto de características é realizada por meio da meta-heurística *Simulated Annealing* (SA), utilizando o ecossistema *D-Wave Ocean SDK*. O algoritmo é executado por 1.000 iterações, retornando a configuração binária associada à menor energia encontrada durante o processo de otimização.

4.4.3 Treinamento

Definidos os subconjuntos de atributos para cada *fold* de treinamento, inicia-se a etapa de treinamento dos seis classificadores avaliados neste trabalho: Random Forest, K-Nearest Neighbors (KNN), Support Vector Machine (SVM), XGBoost, CatBoost e Optimum-Path Forest (OPF). Cada algoritmo será treinado utilizando exclusivamente o subconjunto de características selecionado pelo respectivo método de seleção, permitindo avaliar o impacto de cada abordagem sobre o desempenho preditivo dos classificadores.

Com o objetivo de reduzir o risco de *overfitting* e garantir uma comparação justa entre os modelos, os hiperparâmetros de cada classificador serão ajustados por meio da técnica de *Grid Search*. Para cada combinação previamente definida de hiperparâmetros, o desempenho será estimado utilizando apenas os dados pertencentes ao *fold* de treinamento da iteração corrente, por meio de uma validação cruzada interna. Ao término desse processo, a configuração que apresentar o melhor desempenho médio será selecionada e o classificador será re-treinado utilizando todos os dados do *fold* de treinamento e o subconjunto de características correspondente. Somente após essa etapa o modelo será avaliado sobre o *fold* de teste, garantindo que nenhuma informação proveniente do conjunto de teste influencie o processo de seleção de atributos, otimização de hiperparâmetros ou treinamento do classificador.

4.4.4 Avaliação

A capacidade de generalização dos modelos será avaliada por meio da aplicação dos classificadores ao respectivo *fold* de teste, utilizando dados que permaneceram completamente independentes durante as etapas de seleção de características, otimização de hiperparâmetros e treinamento. Para cada iteração da validação cruzada, serão calculadas cinco métricas de desempenho amplamente empregadas em problemas de classificação: Acurácia, Precisão, *Recall*, *F1-Score* e a Área Sob a Curva ROC (AUC-ROC). Enquanto a acurácia fornece uma medida global da proporção de classificações corretas, a precisão e o *recall* permitem avaliar, respectivamente, a confiabilidade das previsões positivas e a capacidade do modelo em identificar corretamente as amostras pertencentes à classe de interesse. O *F1-Score* combina essas duas métricas em uma única medida harmônica, sendo particularmente útil em cenários com possível desbalanceamento entre as classes. Por sua vez, a AUC-ROC mensura a capacidade discriminativa do classificador ao longo de diferentes limiares de decisão.

Ao término das dez iterações da validação cruzada estratificada, os valores obtidos para cada métrica serão agregados por meio da média aritmética (μ) e do desvio padrão (σ). A média será utilizada como estimativa do desempenho esperado de cada abordagem, enquanto o desvio padrão permitirá analisar a estabilidade dos modelos frente às diferentes partições do conjunto de dados. Posteriormente, os resultados obtidos pelos diferentes métodos de seleção de características serão comparados estatisticamente por meio do teste de Wilcoxon, permitindo verificar se as diferenças observadas são estatisticamente significativas.

4.4.5 Teste Estatístico

Por fim, para verificar se as diferenças de desempenho observadas entre os métodos de seleção de características são estatisticamente significativas, será empregado o teste não paramétrico de Wilcoxon para amostras pareadas. Esse teste será aplicado sobre os resultados obtidos em cada *fold* da validação cruzada, comparando, par a par, as métricas de desempenho produzidas pelos diferentes métodos de seleção. A hipótese nula (H_0) estabelece que não existe diferença estatisticamente significativa entre os métodos comparados, enquanto a hipótese alternativa (H_1) afirma que há diferença significativa entre seus desempenhos.

Será adotado o nível de significância de $\alpha = 0,05$. Dessa forma, valores de $p < 0,05$ levarão à rejeição de H_0 , indicando evidências estatísticas de que os métodos apresentam

desempenhos distintos. Caso contrário ($p \geq 0,05$), não haverá evidências suficientes para rejeitar a hipótese nula, sugerindo que as diferenças observadas podem ser atribuídas à variabilidade amostral. A utilização desse teste permitirá complementar a análise baseada nas métricas de desempenho, fornecendo maior confiabilidade às comparações entre as abordagens avaliadas.

5 CRONOGRAMA

O desenvolvimento deste trabalho foi planejado para ocorrer ao longo de dois semestres letivos. A Tabela 3 apresenta o detalhamento do planejamento mensal:

Tabela 3 – Cronograma de atividades do período de 2026.2

Atividade	Ago.	Set.	Out.	Nov.	Dez.
Implementação dos Algoritmos	x	x			
Testes		x			
Análise de Dados dos Testes		x	x		
Escrita dos Resultados e Trabalhos Futuros			x	x	
Ajustes Finais e Revisão				x	x
Apresentação do TCC II					x

Fonte: Elaborado pela autor (2026).

REFERÊNCIAS

- BARRETO, A. G.; FANCHINI, F. F.; PAPA, J. P.; ALBUQUERQUE, V. H. C. de. Why consider quantum instead classical pattern recognition techniques? **Applied Soft Computing**, Elsevier, v. 165, p. 112096, 2024.
- BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006. ISBN 978-0387-31073-2.
- BREIMAN, L. Random forests. **Machine Learning**, Kluwer Academic Publishers, v. 45, n. 1, p. 5–32, 2001.
- CHAMOLA, V.; JOLFAEI, A.; CHANANA, V.; PARASHARI, P.; HASSIJA, V. Information security in the post quantum era for 5g and beyond networks: Threats to existing cryptography, and post-quantum cryptography. **Computer Communications**, v. 176, p. 99–118, 2021.
- CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 2016. p. 785–794.
- DEMSAR, J. Statistical comparisons of classifiers over multiple data sets. **Journal of Machine Learning Research**, v. 7, n. 1, p. 1–30, 2006.
- FAWCETT, T. An introduction to roc analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006.
- GALVÃO, L. Q.; PIRES, O.; CHAGAS, Y. A.; FRAGA, M. H.; MORET, M. A. Resolução de problemas de seleção de características com algoritmos quânticos em dados financeiros reais. In: **XXVII ENMC - Encontro Nacional de Modelagem Computacional e XV ECTM - Encontro de Ciência e Tecnologia de Materiais**. Ilhéus, Bahia, Brazil: [s.n.], 2024. LAQCC - Latin American Quantum Computing Center, SENAI CIMATEC.
- GeeksforGeeks. **CatBoost in Machine Learning**. 2025. GeeksforGeeks. Acessado em: 18 de junho de 2026. Disponível em: <<https://www.geeksforgeeks.org/machine-learning/catboost-ml/>>.
- GIOBERGIA, F.; SAVELLI, C.; KOUDOUNAS, A.; BARALIS, E. Quantum feature selection from interpretable models using a qubo formulation. In: **CLEF 2025 Working Notes**. Madrid, Spain: [s.n.], 2025. (CEUR Workshop Proceedings).
- HASAN, M. J.; MAHDY, M. R. C. Bridging classical and quantum machine learning: Knowledge transfer from classical to quantum neural networks using knowledge distillation. **Research Article**, 2024.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The elements of statistical learning: data mining, inference, and prediction**. New York: Springer Science & Business Media, 2009.
- KADOWAKI, T.; NISHIMORI, H. Quantum annealing in the transverse ising model. **Physical Review E**, APS, v. 58, n. 5, p. 5355, 1998.
- KIRKPATRICK, S.; GELATT, C. D.; VECCHI, M. P. Optimization by simulated annealing. **Science**, American Association for the Advancement of Science, v. 220, n. 4598, p. 671–680, 1983.

- LEDESMA, S.; AVIÑA-CERVANTES, J. G.; SANCHEZ, R. Practical considerations for simulated annealing implementation. In: TAN, C. M. (Ed.). **Simulated Annealing**. Vienna, Austria: InTech, 2008. p. 401–420.
- LI, J.; CHENG, K.; WANG, S.; MORSTATTER, F.; TREVINO, R. E.; TANG, J.; LIU, H. Feature selection: A data perspective. **ACM computing surveys (CSUR)**, ACM, v. 50, n. 6, p. 1–45, 2017.
- LORENA, A. C.; CARVALHO, A. C. P. L. F. d. Uma introdução às support vector machines. **Revista de Informática Teórica e Aplicada**, v. 14, n. 2, p. 43–67, 2007. ISSN 0103-4308.
- MARTÍNEZ-GARCÍA, F.; RUBIO-GARCÍA, A.; FERNÁNDEZ-LORENZO, S.; GARCÍA-RIPOLL, J. J.; PORRAS, D. Optimised feature subset selection via simulated annealing. **Machine Learning: Science and Technology**, IOP Publishing, v. 6, p. 045059, 2025.
- MOLINO-PIÑAR, L.; COLLADO-MONTAÑEZ, J.; MONTEJO-RÁEZ, A. Sinai team at quantumclef 2025: quantum feature selection based on energy with d-wave. In: **CLEF 2025 Working Notes**. Madrid, Spain: [s.n.], 2025. (CEUR Workshop Proceedings).
- NAU, M. A.; NUTRICATI, L. A.; CAMINO, B.; WARBURTON, P. A.; MAIER, A. K. Quantum annealing feature selection on light-weight medical image datasets. **Scientific Reports**, Nature Publishing Group, v. 15, n. 1, p. 28937, 2025.
- NTI, I. K.; NYARKO-BOATENG, O.; ANING, J. Performance of machine learning algorithms with different k values in k-fold cross-validation. **International Journal of Information Technology and Computer Science**, v. 13, n. 6, p. 61–71, 2021.
- OZTORNACI, B.; ATA, B.; KARTAL, S. Analysing household food consumption in turkey using machine learning techniques. **AGRIS on-line Papers in Economics and Informatics**, v. 16, n. 2, p. 97–105, 2024. ISSN 1804-1930.
- PAPA, J. P.; FALCÃO, A. X.; SUZUKI, C. T. N. Supervised pattern classification based on optimum-path forest. **International Journal of Imaging Systems and Technology**, v. 19, n. 2, p. 120–131, 2009.
- PENG, H.; LONG, F.; DING, C. Feature selection based on mutual information: Criteria of max-dependency, max-relevance, and min-redundancy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, IEEE Computer Society, v. 27, n. 8, p. 1226–1238, 2005.
- PROKHORENKOVA, L.; GUSEV, G.; VOROBEOV, A.; DOROGUSH, A. V.; GULIN, A. CatBoost: unbiased boosting with categorical features. In: **Proceedings of the 32nd International Conference on Neural Information Processing Systems (NeurIPS 2018)**. Montréal, Canada: [s.n.], 2018. p. 6639–6649. Disponível em: <<https://papers.nips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html>>.
- Scikit-learn Developers. **Cross-validation: Evaluating estimator performance**. 2025. <https://scikit-learn.org/stable/modules/cross_validation.html>. Acesso em: 08 ago. 2026.
- SHAIKH, M. T.; HAMZA, M.; ALI, S. B.; RAFI, M.; ZAHID, S. Feature selection using quantum annealing: a mutual information based qubo approach. In: **CLEF 2025 Working Notes**. Madrid, Spain: [s.n.], 2025. (CEUR Workshop Proceedings).

SUN, Q.; ZHONG, J.; SHI, P.; XU, H.; WANG, Y. An improved reactive force field parameter optimization framework based on simulated annealing and particle swarm optimization algorithms. **Computational Materials Science**, Elsevier, v. 251, p. 113776, 2025.

WINTER, J. C. F. de; GOSLING, S. D.; POTTER, J. Comparing the Pearson and Spearman correlation coefficients across distributions and sample sizes: A tutorial using simulations and empirical data. **Psychological Methods**, v. 21, p. 273–290, 2016.

YE, L.; WEN, M.; ZHANG, F.; XU, Y.; ZHANG, Y.; MA, Y.; WEN, K. Hybrid quantum-classical algorithm for an integrated feature selection and logistic regression model. **IEEE Transactions on Engineering Management**, IEEE, 2026.

YU, T.; ZHU, H. Hyper-parameter optimization: A review of algorithms and applications. **arXiv preprint arXiv:2003.05689**, 2020.

ZHANG, Z. Introduction to machine learning: k-nearest neighbors. **Annals of Translational Medicine**, v. 4, n. 11, p. 218, 2016.